Лабораторная работа №1

Диагностика обучения MLP

Содержание

1. Подготовка выборок и первичная диагностика 2
2. Базовая MLP и цикл обучения 3
3. Контролируемые эксперименты 4
4. Диагностика градиентов 6
5. Выбор модели, итоговая оценка и выводы 9

Выполнил: Михаил Сибиряков
Группа: 24ТИДИ

2026

Цель: сопоставить активации, инициализацию, режимы оптимизации и глубину MLP на одной задаче.

1. Подготовка выборок и первичная диагностика

Использован `make_moons`: 2400 объектов, `noise=0.25`, `random_state=2026`. Два стратифицированных разбиения с тем же random state выделяют 20% данных в test, затем 25% оставшихся — в validation. Эти параметры заданы в `lab1.pdf`; выборки одинаковы во всех запусках.

Таблица 1: Размеры выборок и баланс классов.

Выборка	Объектов	Класс 0	Класс 1
Train	1440	720	720
Validation	480	240	240
Test	480	240	240

`StandardScaler` вычисляет средние и стандартные отклонения по train и применяет их к validation и test. Эти выборки имитируют новые данные: учёт их статистик при обучении скалера означал бы утечку информации и искажал оценку обобщения. На train после масштабирования средние равны $(3.91 \times 10^{-10}, -2.71 \times 10^{-10})$, стандартные отклонения — $(0.9999999981, 1.0000000005)$.



Рис. 1: Обучающие объекты до масштабирования; цвет обозначает класс.

2. Базовая MLP и цикл обучения

Два входных признака проходят через L скрытых слоёв ширины 32 с одной выбранной активацией, затем через линейный выход из двух логитов:

$$h_0 = x, \quad z_l = W_l h_{l-1} + b_l, \quad h_l = \varphi(z_l), \qquad z_{\text{out}} = W_{L+1} h_L + b_{L+1}.$$

Матрицы весов имеют размеры 32×2, затем 32×32, на выходе — 2×32. С учётом смещений число параметров:

$$P(L) = 32(2+1) + (L-1)32(32+1) + 2(32+1) = 162 + 1056(L-1).$$

Это 162 параметра при одном скрытом слое и 5442 при шести.

Таблица 2: Варианты эксперимента; буквы используются как краткие обозначения.

Код	L	Активация	Скрытые веса	Оптимизатор	LR
A	6	Sigmoid	Xavier normal	Adam	0.003
B	6	Tanh	Xavier normal	Adam	0.003
C	6	ReLU	Xavier normal	Adam	0.003
D	6	ReLU	He normal	Adam	0.003
E	6	ReLU	He normal	SGD	0.05
F	1	ReLU	He normal	Adam	0.003

Инициализация. Скрытые веса заданы явно: Xavier normal с gain 1 либо He normal с `fan_in` и `relu`. Выходные веса всегда Xavier normal с gain 1, все смещения нулевые.

Обучение. Каждый вариант обучен с seed 11 и 29: 100 эпох, батч 128, перемешивание train в каждой эпохе; последний батч из 32 объектов сохраняется. Перед созданием модели вызывается `torch.manual_seed(seed)`, для DataLoader создаётся новый генератор с seed $10000 + \text{seed}$, как требует задание. CPU, один поток PyTorch; признаки `float32`, метки `long`. У SGD momentum равен нулю; остальные параметры оптимизаторов по умолчанию. Scheduler, dropout, batch normalization, weight decay, early stopping и предобучение не применяются.

Шаг в режиме `train`: обнуление градиентов, forward, средний `CrossEntropyLoss`, backward, шаг оптимизатора. До обучения и после каждой эпохи полные train и validation оцениваются в режимах `eval` и `no_grad`. Loss усредняется с весом по размеру батча; accuracy — доля правильных ответов по arg max логитов.

Самопроверки пройдены. На батче из 8 объектов формы входа и выхода равны $(8, 2)$, loss скалярный и конечный. Числа параметров совпали с расчётом. Градиенты всех скрытых весов существуют, конечны и имеют формы самих весов; инициализация повторяется при одинаковом seed. Эксперименты начинают с новых моделей.

3. Контролируемые эксперименты

Сохранены все 1212 записей метрик; loss конечен, accuracy в $[0, 1]$. Таблица 3 содержит результаты на эпохе 100. Числа для чтения округлены до четырёх знаков; выбор выполнен по исходным значениям CSV/JSON.

Таблица 3: Итоговые метрики: слева оба seed каждого варианта, справа средний validation loss.

Код	Seed	$\mathcal{L}_{\text{train}}$	a_{train}	$\mathcal{L}_{\text{val}}$	a_{val}
A	11	0.1505	0.9458	0.1907	0.9167
A	29	0.1403	0.9458	0.1771	0.9167
B	11	0.1467	0.9465	0.2034	0.9125
B	29	0.1436	0.9486	0.1893	0.9187
C	11	0.1212	0.9507	0.1770	0.9229
C	29	0.1263	0.9472	0.2073	0.9104
D	11	0.1080	0.9576	0.1956	0.9125
D	29	0.1153	0.9549	0.2069	0.9083
E	11	0.2271	0.9035	0.3169	0.8708
E	29	0.3074	0.8639	0.3597	0.8438
F	11	0.1367	0.9493	0.1678	0.9292
F	29	0.1382	0.9493	0.1676	0.9229

Код	Средний loss
A	0.1839
B	0.1963
C	0.1921
D	0.2013
E	0.3383
F	0.1677

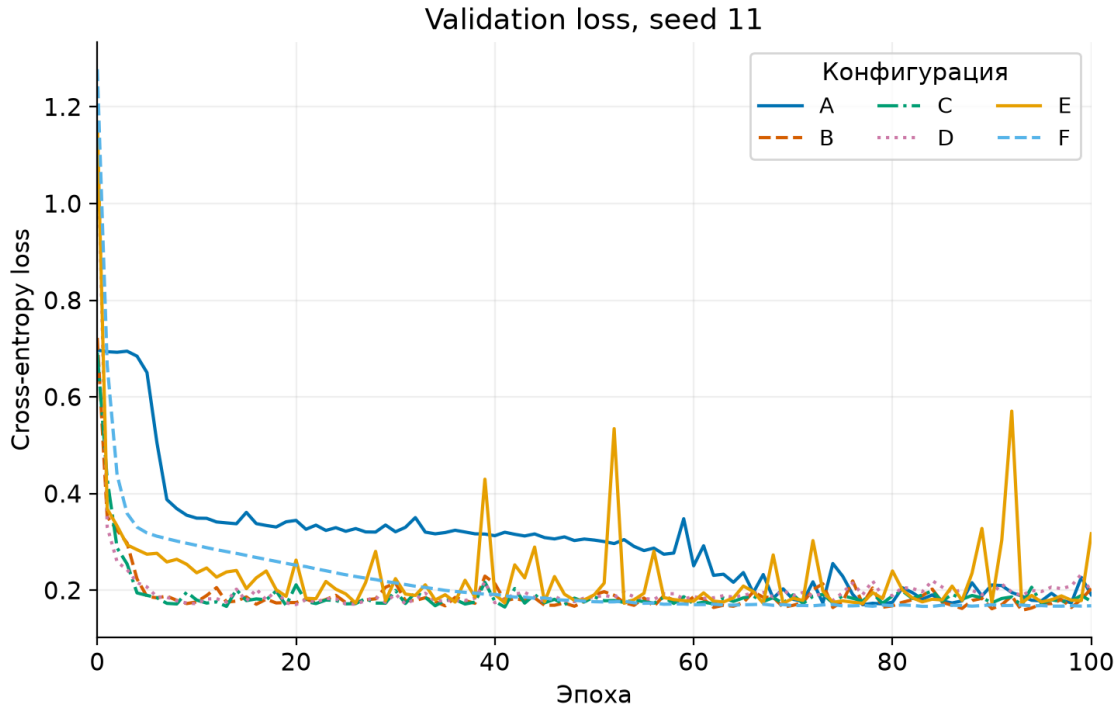


Рис. 2: Validation loss: все варианты, seed 11, эпохи 0–100.

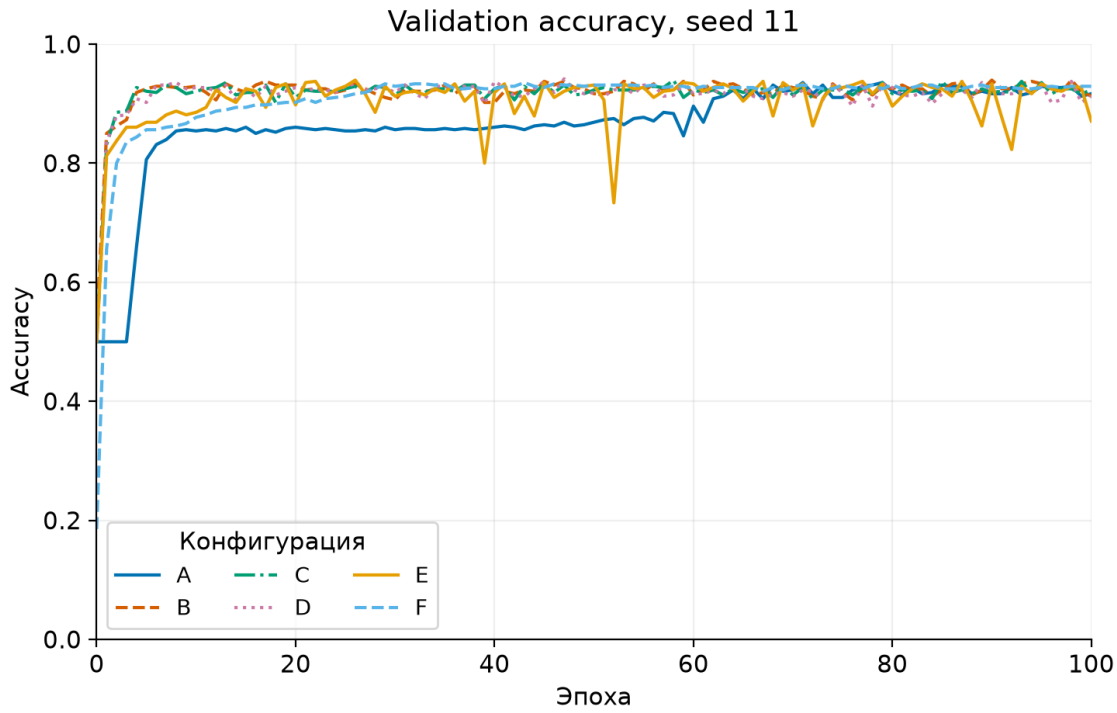


Рис. 3: Validation accuracy тех же запусков; значения записаны долями.

Таблица 4: Validation loss в начале обучения: сравнение обоих seed.

Вариант	Эпоха 5		Эпоха 20	
	Seed 11	Seed 29	Seed 11	Seed 29
Sigmoid / Xavier (A)	0.6505	0.6688	0.3445	0.3271
Tanh / Xavier (B)	0.1871	0.2647	0.1745	0.1741
ReLU / Xavier (C)	0.1893	0.1866	0.2112	0.1762
ReLU / He (D)	0.2068	0.1986	0.1704	0.1690
ReLU / He / SGD (E)	0.2745	0.2816	0.2624	0.2124
ReLU / He / 1 слой (F)	0.3186	0.3301	0.2518	0.2704

Активации: Sigmoid, Tanh и ReLU. Шестислойная сеть с Sigmoid (A) медленнее стартует в обоих запусках. Tanh (B) и ReLU (C) уже в первые эпохи существенно уменьшают loss (таблица 4). Это согласуется с различием производных активаций и начальными градиентами, рассмотренными ниже. Позже Sigmoid сокращает отставание. На эпохе 100 среди этих трёх вариантов при seed 11 меньше loss у ReLU, а при seed 29 — у Sigmoid. Быстрый старт не задаёт устойчивого итогового порядка; вывод относится к заданной Xavier-инициализации.

ReLU: Xavier и He. He-инициализация (D) увеличивает начальные градиенты относительно Xavier (C) и к эпохе 20 даёт меньший validation loss в обоих запусках. На финальной эпохе преимущество не сохраняется: при seed 11 результат He хуже, при seed 29 варианты почти равны. При этом train loss у He ниже в обоих запусках. Следовательно, изменение масштаба

весов помогло динамике обучения, но не обеспечило устойчивого выигрыша на отложенных данных.

Режимы Adam и SGD. Глубокая ReLU-сеть с Adam (D) быстрее снижает loss и заканчивает с меньшим loss, чем вариант с SGD (E), в обоих seed. У SGD кривая заметно колеблется: после первых десяти эпох validation loss в обоих запусках временами превышает 0.5. Adam адаптирует шаг по координатам с учётом статистик градиента; SGD здесь использует постоянный шаг без momentum. Но одновременно меняются оптимизатор и learning rate: сравниваются два заданных режима, а не изолированное влияние оптимизатора.

Один скрытый слой и шесть. Добавление слоёв увеличило число параметров. Глубокая сеть (D) быстрее стартует и лучше подгоняет train, но имеет больший validation loss, чем однослойная (F), в обоих seed. Это согласуется с переобучением более крупной модели; эффект глубины при одинаковом числе параметров здесь не проверен.

4. Диагностика градиентов

Probe — первые 128 масштабированных train-объектов в исходном порядке. Для Sigmoid/Xavier (A), ReLU/Xavier (C), ReLU/He (D) и обоих seed на эпохах 0, 20 и 100 измерены нормы градиентов скрытых весов:

$$g_l(t) = \left\| \frac{\partial \mathcal{L}_{\text{probe}}(t)}{\partial W_l} \right\|_F, \qquad \mathcal{L}_{\text{probe}} = \text{CE}(f_{\theta_t}(X_{\text{probe}}), y_{\text{probe}}).$$

Перед отдельным forward/backward и после него градиенты очищаются; шаг оптимизатора не выполняется. Неизменность весов проверена. Смещения и выходной слой в профиль не входят. Все 108 норм конечны и положительны; нулевых значений нет. Полные измерения обоих seed сохранены в `results/gradients.csv`; в таблице 5 выделены первый и последний скрытые слои.

Почему Sigmoid стартует медленнее. По правилу цепочки обратный сигнал умножается на производные активаций:

$$\delta_l = (W_{l+1}^{\mathsf{T}} \delta_{l+1}) \odot \varphi'(z_l), \qquad \frac{\partial \mathcal{L}_{\text{probe}}}{\partial W_l} = \frac{1}{128} \sum_i \delta_{l,i} h_{l-1,i}^{\mathsf{T}}.$$

Здесь $\delta_{l,i}$ относится к loss отдельного объекта до усреднения. Производная Sigmoid не превышает $1/4$, что способствует ослаблению сигнала к ранним слоям; итог зависит также от весов. Для Tanh верхняя граница равна 1, но при насыщении производная мала. У ReLU производная на активных путях равна 1.

В начале у Sigmoid норма первого слоя на несколько порядков меньше нормы последнего. У ReLU такого контраста нет. Этот результат повторяется при seed 29 и согласуется с медленным начальным снижением loss. После обучения профиль Sigmoid меняется: ранние слои уже не имеют меньших норм.

Таблица 5: Нормы первого и последнего скрытых слоёв: начало и конец обучения. Полные профили сохранены в CSV.

Вариант	Seed	Эпоха 0		Эпоха 100	
		g_1	g_6	g_1	g_6
Sigmoid / Xavier (A)	11	1.52×10^{-4}	6.56×10^{-2}	1.01×10^{-1}	3.27×10^{-2}
Sigmoid / Xavier (A)	29	1.90×10^{-4}	1.22×10^{-1}	7.40×10^{-2}	1.93×10^{-3}
ReLU / Xavier (C)	11	4.51×10^{-2}	8.55×10^{-2}	1.28×10^{-1}	2.76×10^{-2}
ReLU / Xavier (C)	29	9.65×10^{-2}	9.25×10^{-2}	2.35×10^{-1}	2.38×10^{-2}
ReLU / He (D)	11	3.09×10^{-1}	4.04	4.88×10^{-2}	8.34×10^{-2}
ReLU / He (D)	29	2.65×10^{-1}	9.64×10^{-1}	1.56×10^{-1}	1.04×10^{-1}

Что меняет He и чего норма не объясняет. Не даёт более крупные начальные нормы, чем Xavier, в обоих seed. К эпохе 100 порядок зависит от слоя: у He норма первого слоя меньше, а последнего больше, чем у Xavier. Начальное увеличение норм не означает их постоянного превосходства или меньшего итогового validation loss.

Градиент весов зависит и от обратного сигнала, и от входных активаций. Первый слой содержит 64 веса, последующие — по 1024; норма Фробениуса учитывает все элементы матрицы. Поэтому профиль не измеряет изолированно передачу ошибки. Кроме того, фиксированный probe отличается от обучающего батча, а обновление всей модели зависит от направления градиента, learning rate и оптимизатора. Одной нормы недостаточно для предсказания скорости снижения validation loss.

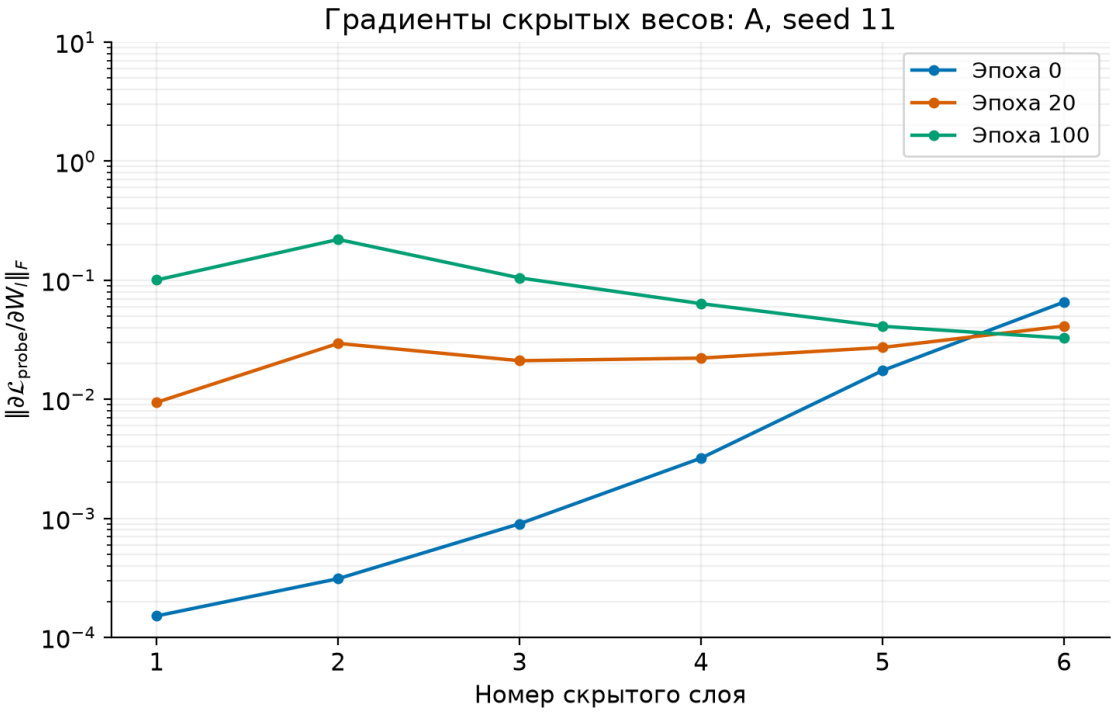


Рис. 4: Sigmoid/Xavier (A): нормы градиентов скрытых весов при seed 11.

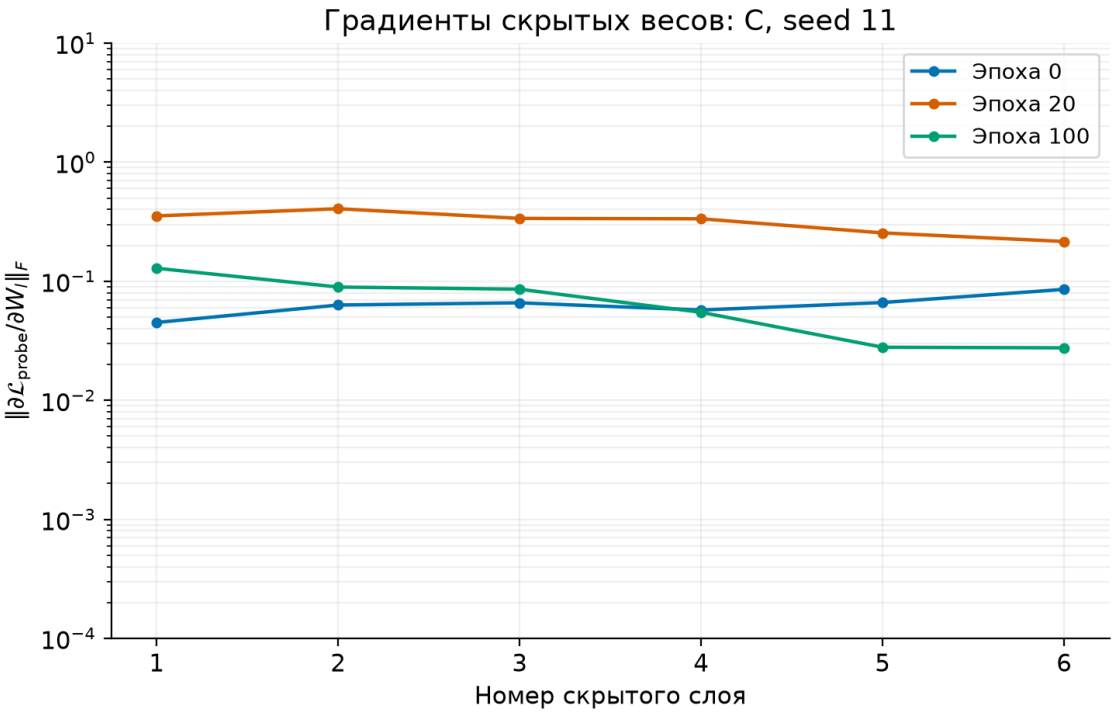


Рис. 5: ReLU/Xavier (C): те же эпохи и логарифмическая шкала.

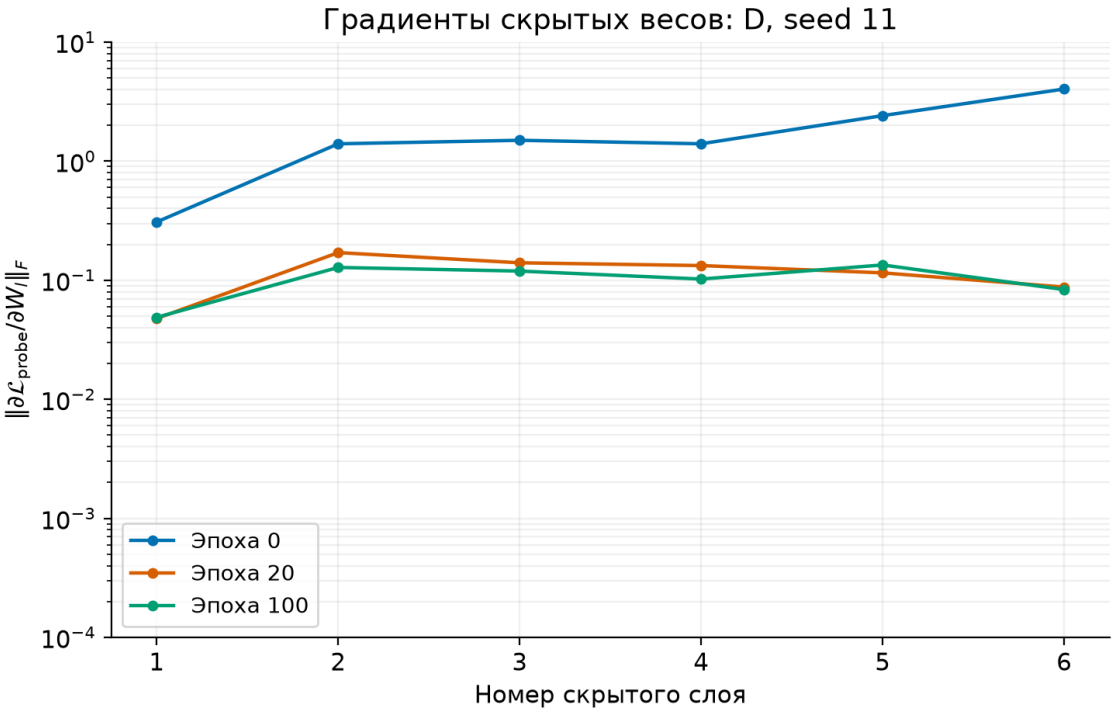


Рис. 6: ReLU/He (D). Пределы оси Y одинаковы на трёх графиках.

5. Выбор модели, итоговая оценка и выводы

Сначала по среднему validation loss двух seed на эпохе 100 выбрана конфигурация F; затем внутри неё — seed 29 с меньшим validation loss. Точные ничьи разрешаются по букве конфигурации, затем в пользу seed 11. Test оценён после выбора на весах эпохи 100; настройки по нему не менялись.

Таблица 6: Качество выбранной однослойной сети, seed 29, эпоха 100.

Выборка	Loss	Accuracy
Train	0.1382	0.9493
Validation	0.1676	0.9229
Test	0.1314	0.9500

Train loss продолжает снижаться, а validation loss к концу выходит на плато. Признаков длительного застоя оптимизации нет, хотя ошибки на train сохраняются. Разрыв accuracy между train и validation составляет около 2.6 процентного пункта: качество на отложенных данных ниже, несмотря на улучшение обучающего loss. Test здесь лучше validation; для двух конечных выборок по 480 объектов это возможно и не служит основанием менять процедуру выбора.

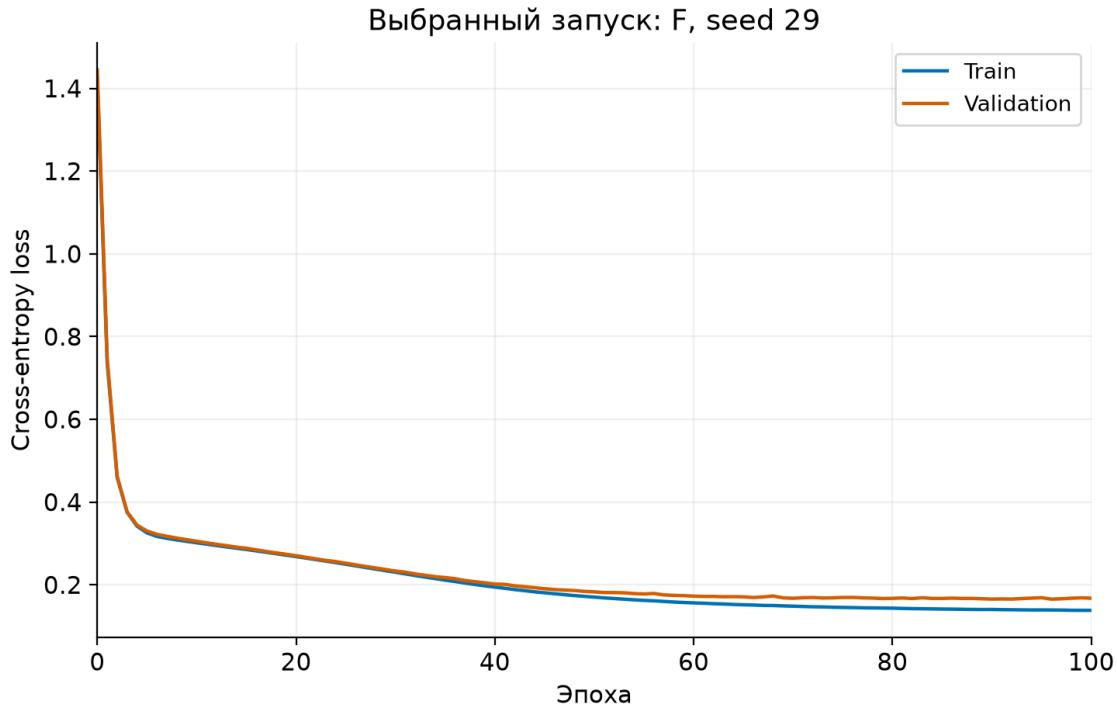


Рис. 7: Выбранная однослойная сеть F, seed 29: train и validation loss.

Выводы

1. **Малые начальные градиенты согласуются с медленным стартом.** При seed 11 норма первого слоя Sigmoid около 1.5×10^{-4}, у ReLU/Xavier — 4.5×10^{-2}. Повторное умножение на малые производные объясняет этот контраст; после обучения он меняется.
2. **Результат зависит от режима обновлений.** У глубокой ReLU-сети средний итоговый validation loss с Adam около 0.201, с SGD — 0.338. Адаптация шага и различие learning rate меняют траекторию, но этот опыт не разделяет их влияния.
3. **Лучшее обучение train не гарантирует лучшего обобщения.** Глубокая сеть получает меньший train loss, но средний validation loss у однослойной сети лучше: 0.168 против 0.201. Для этой задачи меньшая модель оказалась достаточной.

Обобщение «неглубокие сети всегда лучше глубоких» здесь не обосновано: проверены одна задача, одно разбиение и два seed, а число параметров меняется вместе с глубиной. По тем же причинам результаты не доказывают универсального превосходства активации или оптимизатора.